INFORME EXPLICATIVO AMPLIADO / 22 DE OCTUBRE DE 2026

Etapa 2, paso a paso

Predicción de subidas de buses en Santiago
Decisiones, términos y tablas antes y después

Pregunta del proyecto. ¿Cuántas subidas promedio registrará una comuna, en un tipo de día y una franja de 30 minutos, en un próximo período publicado? La etapa 2 prepara los datos, explora patrones y prueba tres formas de responderla.

Término	Significado preciso en este proyecto
Corte	Una publicación para un período determinado, basada en una semana o muestra representativa. Es una fotografía temporal.
Fila o registro	Una observación de la tabla. En el Excel original corresponde a un paradero, día y horario; en el panel corresponde a una comuna, día, horario y corte.
Columna o variable	Una característica de la fila: comuna, tipo_dia, media_hora o subidas_promedio, por ejemplo.
Celda	El valor en el cruce de una fila y una columna. Al hablar de una celda de demanda se alude a la combinación corte + comuna + día + horario y su valor objetivo.
Objetivo o target	El número que se quiere pronosticar: Subidas_Promedio de BUS sumadas en esa combinación.
Panel	Una tabla que sigue las mismas combinaciones de comuna, día y franja a través de varios cortes.

Cómo leer las explicaciones

Cada transformación muestra **qué se hace, por qué y qué se gana o se pierde**. Las tablas de datos son ejemplos reales del repositorio; las operaciones sobre ellos se recalculan. Los ejemplos numéricos genéricos, cuando aparecen, se identifican como ilustrativos.

El posible uso es apoyar la planificación de frecuencias y flota del DTPM / Red Movilidad. La implementación predice la medida publicada de subidas y no corrige por evasión ni demuestra aún efectos sobre esperas, frecuencias o capacidad. [A, D, G]

Ruta de lectura: fuente (p. 2), filtros (p. 3), suma de paraderos (p. 4), cobertura (p. 5), ceros (p. 6), auditoría (p. 7), hallazgos (p. 8), modelo (p. 9), validación (p. 10), errores (p. 11), decisiones pendientes (p. 12) y defensa oral/fuentes (p. 13).

ETAPA II / 02

La fuente original: qué mide cada campo

El pipeline selecciona cuatro libros de **Subidas por Paradero y Estación**: noviembre de 2024, abril de 2025 (versión v2), noviembre de 2025 y abril de 2026. El nombre del corte identifica el período de publicación; no representa una observación de cada día entre 2024 y 2026. [A, G]

Antes: estructura real del Excel de abril de 2026

Col. Excel	Nombre original	Qué representa
A	Tipo_dia	LABORAL, SABADO o DOMINGO; agrupa días de ese tipo.
B	Modo	BUS, Metro o Tren. Permite elegir el modo de transporte.
C	Paradero	Código del punto de subida reportado.
D	Paradero Usuario	Otra identificación del paradero.
E	Comuna	Comuna asignada; también puede aparecer SIN_COMUNA.
F	Media_hora	Inicio de la franja; por ejemplo, 00:30 representa 00:30-01:00.
G	Subidas_Promedio	La medida promedio publicada para esa fila. Puede contener decimales.

Ejemplo real: la fila **206678** de la hoja SUBIDAS_2026_04 contiene LABORAL, BUS, paradero L-12-13-35-OP, código usuario PI24, comuna CERRILLOS, hora 00:30 y valor **0,4**. Su celda G206678 contiene ese 0,4. [O]

Después: qué conserva el panel comunal

Campo del panel	Procedencia o cambio
periodo	Se añade a partir del libro: 2026-04 en este ejemplo.
comuna / tipo_dia / media_hora	Son las claves para agrupar filas del mismo contexto.
subidas_promedio	Se suman los valores de los paraderos del grupo.
Modo y códigos de paradero	Modo deja de variar al filtrar BUS; los códigos no son claves del panel comunal.

Por qué se hace: la pregunta implementada está definida por comuna. Reunir los paraderos permite comparar esa escala geográfica entre cortes.

Qué implica: se pierde el detalle por paradero en el panel. Ese detalle sigue en los Excel y sería necesario para pronosticar o planificar cada parada.

Etapas = un tramo de un recorrido; Viajes = el recorrido completo; Subidas = la medida elegida aquí. Los ZIP históricos de Etapas/Viajes están disponibles, pero no fueron armonizados como entradas de este modelo. Por eso se conserva el target histórico ya procesado. [G]

ETAPA II / 03

Qué se filtra y qué solo cambia de formato

Antes y después del filtro de modo: ejemplos reales

Fila Excel	Modo	Comuna	Valor	¿Entra al panel observado?
15359	BUS	CERRILLOS	1	Sí: se agrega a su grupo.
174621	Metro	LAS CONDES	14	No: fuera del alcance BUS.
161903	BUS	BUIN	1	Sí: la restricción geográfica viene después.
101414	BUS	SIN_COMUNA	1	Sí: se conserva para auditar.

Hoja SUBIDAS_2026_04. Son filas fuente seleccionadas, no una tabla contigua ni el panel ya agregado. [O]

Por qué: el objetivo está definido para buses. Metro y Tren se excluyen de la salida BUS y permanecen intactos en el Excel original.

Corte	Filas examinadas	Otros modos	BUS incluido
2024-11	783.557	15.681	767.876
2025-04	747.599	14.044	733.555
2025-11	778.092	14.177	763.915
2026-04	761.557	14.022	747.535

En total, el reporte registra **57.924 filas de otros modos excluidas** y **3.012.881 filas BUS incluidas**. Para abril de 2026 se verificaron directamente 13.015 filas Metro y 1.007 Tren, que suman 14.022. [B, O]

Normalizar es hacer comparables las etiquetas

Antes	Después	Motivo
Media_hora = 00:30:00	media_hora = 00:30	Misma franja, formato uniforme.
Tipo_dia / Subidas_Promedio	tipo_dia / subidas_promedio	Nombres consistentes en el CSV.
Bus o BUS	BUS	Regla del código: diferencias de mayúsculas no crean modos distintos.
MAIPÊ	MAIPÚ	Alias documentado en el código para reparar la conversión antigua.

Las dos primeras filas usan el esquema del libro revisado. Las otras son reglas del código, no filas extraídas de ese libro. Se reparan etiquetas, no cantidades de subidas. [A, O]

> El código controla días ausentes, horas inválidas y objetivos inválidos o negativos. El reporte registra **0 descartes por esas causas**. No se eliminaron miles de filas por nulos o por outliers. [B]

ETAPA II / 04

De cinco paraderos a una fila comunal

Grupo real: abril de 2026, CERRILLOS, LABORAL, franja 00:30-01:00. Se recorrió la hoja completa y se encontraron estas cinco filas BUS para esa combinación. [O]

Antes: cinco registros de paraderos

Fila Excel	Paradero	Código usuario	Subidas_Promedio
206678	L-12-13-35-OP	PI24	0,4
208628	L-12-25-30-SN	PI33	0,2
210636	L-12-35-7-SN	PI1155	0,2
422441	T-12-88-SN-15	PI119	0,2
422515	T-12-89-OP-10	PI58	0,4

Operación: 0,4 + 0,2 + 0,2 + 0,2 + 0,4 = **1,4 subidas promedio agregadas**.

Después: una fila del panel observado

periodo	comuna	tipo_dia	media_hora	subidas_promedio
2026-04	CERRILLOS	LABORAL	00:30	1,4

Fila 14955 de panel_demanda_bus.csv (contando encabezado como línea 1). La suma fue contrastada contra el CSV. [C]

¿Por qué sumar y no promediar otra vez?

La pregunta pide el volumen agregado de la comuna para el mismo día y franja. Cada paradero aporta al grupo. Promediar los cinco valores daría **0,28 por fila de paradero**, una medida diferente de la suma comunal de 1,4.

La etiqueta “promedio” ya viene de la fuente: el código suma esa medida publicada. Un resultado como 1,4 es válido porque es un promedio agregado; no significa observar una fracción de una persona en una subida individual.

Qué cambia al agrupar

Aspecto	Antes	Después
Nivel de detalle	Paradero	Comuna
Cantidad de filas del ejemplo	5	1
Suma de la medida del ejemplo	1,4	1,4

La suma se conserva; el detalle por paradero permanece en el Excel. El panel comunal ya no permite separar sus aportes individuales.

ETAPA II / 05

Por qué se excluyen algunas comunas del modelo

La cobertura de las fuentes cambia: hay 36 comunas en noviembre de 2024, 36 más SIN_COMUNA en abril y noviembre de 2025, y 39 más SIN_COMUNA en abril de 2026. El modelo conserva la **intersección**: las 36 comunas presentes en los cuatro cortes. [A, B]

Antes y después: filas reales del panel observado

Comuna / día / hora	Valor observado	En panel del modelo	Decisión
CERRILLOS LABORAL 00:30	1,4	Sí	Comuna común
BUIN DOMINGO 19:00	1	No	Solo aparece en 2026-04
SIN_COMUNA DOMINGO 00:30	1	No	Sin comuna asignable

BUIN, COLINA y PIRQUE: tienen registros válidos en abril de 2026, pero no aparecen en los otros tres cortes. **SIN_COMUNA:** es una etiqueta de registros sin asignación comunal; no identifica una comuna sobre la que se pueda emitir el pronóstico geográfico.

Cuántas filas observadas se excluyen

Corte	SIN_COMUNA	Buin	Colina	Pirque	Total
2024-11	0	0	0	0	0
2025-04	39	0	0	0	39
2025-11	110	0	0	0	110
2026-04	101	14	79	59	253

402 filas excluidas del panel de modelamiento = 250 SIN_COMUNA + 14 de Buin + 79 de Colina + 59 de Pirque. Todas permanecen en el panel observado y en las fuentes.

Por qué se hace: usar la misma cobertura permite comparar modelos y períodos sin que entren comunas nuevas al final. También asegura antecedentes de cada comuna para los baselines.

Qué implica: el pronóstico cubre 36 comunas y deja fuera algunas zonas válidas de abril de 2026. Es una decisión de comparabilidad del análisis actual, no una prueba de que sus datos sean erróneos.

¿Por qué no completar también Buin con ceros en 2024 y 2025? No tener esa comuna cubierta no demuestra demanda cero. El código primero fija las comunas comunes y solo después completa celdas de día y horario dentro de esa cobertura.

ETAPA II / 06

Qué celda tiene cero y de dónde salió

> **Clave real del ejemplo:** comuna CERRILLOS, tipo de día LABORAL, franja 02:00-02:30. Al cambiar el corte, cambia la observación. La celda que interesa es su valor en **subidas_promedio**.

Antes: panel observado, abril de 2025

Comuna	Día	Hora	subidas_promedio
CERRILLOS	LABORAL	01:30	0,6
CERRILLOS	LABORAL	02:00	No existe esa fila
CERRILLOS	LABORAL	02:30	0,2

Se muestran las filas vecinas y se señala la ausencia. “No existe esa fila” es una anotación explicativa; no es un texto que aparezca en el CSV. [C]

Después: panel para modelar, abril de 2025

Comuna / día	Hora	subidas_promedio	relleno_cero
CERRILLOS / LABORAL	01:30	0,6	0
CERRILLOS / LABORAL	02:00	**0**	**1**
CERRILLOS / LABORAL	02:30	0,2	0

La fila añadida es la línea 5238 de panel_demanda_bus_modelo.csv. La quinta columna vale 0 y la sexta vale 1. [C]

La misma combinación a través de los cuatro cortes

Corte	¿Había fila observada?	Valor en el modelo	relleno_cero
2024-11	Sí	0	0
2025-04	No	0	1
2025-11	Sí	0,4	0
2026-04	Sí	0,4	0

Cero observado: en noviembre de 2024 había una fila agregada con valor 0; se conserva y su marca es 0. **Cero añadido:** en abril de 2025 no había fila; el código crea una con valor 0 y marca 1. **Marca 0 no significa demanda cero:** significa que la combinación estaba presente.

Por qué se hace: se construye una rejilla común que facilita alinear cada combinación entre períodos y calcular los antecedentes.

Qué implica: el valor 0 de una ausencia es una imputación: asignar un valor que no estaba observado. Falta confirmar con el DTPM si la ausencia significa cero o falta de información. El modelo puede aprender de ese supuesto. [A, D]

ETAPA II / 07

Auditoría: qué cambió en cada tabla

Reconciliación completa del panel

Corte	Observadas	Se excluyen	Se conservan	Se añaden	Final
2024-11	4937	0	4937	247	5.184
2025-04	4932	39	4893	291	5.184
2025-11	5026	110	4916	268	5.184
2026-04	5156	253	4903	281	5.184
TOTAL	20.051	402	19.649	1.087	20.736

Antes: 20.051 filas del panel observado.
Después: 20.051 - 402 + 1.087 = **20.736** filas.
Control: 36 comunas × 3 tipos de día × 48 franjas × 4 cortes = 20.736.

Las 48 franjas provienen de dividir las 24 horas del día en bloques de 30 minutos. “Panel balanceado” significa que cada corte tiene las mismas 5.184 combinaciones. Esa regularidad es una decisión del pipeline; otros métodos podrían manejar ausencias de otra forma.

No todos los ceros significan lo mismo

Corte	Ceros ya observados en el panel	Ceros añadidos	Ceros finales
2024-11	197	247	444
2025-04	0	291	291
2025-11	0	268	268
2026-04	0	281	281
TOTAL	197	1.087	1.284

El reporte fuente registra **109.453 filas BUS con cero explícito** en noviembre de 2024. Ese número es a nivel de paradero. Después de sumar paraderos, quedan **197 combinaciones comunales observadas con suma cero**. Los conteos miden unidades diferentes: varias filas fuente pueden formar una sola fila comunal. [B, C]

Por qué conservar el panel observado y el del modelo

El **panel observado** permite comprobar qué combinaciones estaban presentes. El **panel del modelo** añade la cobertura común y el relleno para el experimento. Conservar ambos permite auditar cada valor añadido. El JSON guarda controles; el CSV de métricas guarda errores y la carpeta figuras contiene los gráficos. Los nombres y rutas están en las fuentes de la página 13.

ETAPA II / 08

Qué se observa y por qué importa

La exploración comprueba si hay estructura que el historial pueda ayudar a pronosticar. Se describe la misma cobertura de 36 comunas y la misma medida, para mantener comparabilidad. [C, D]

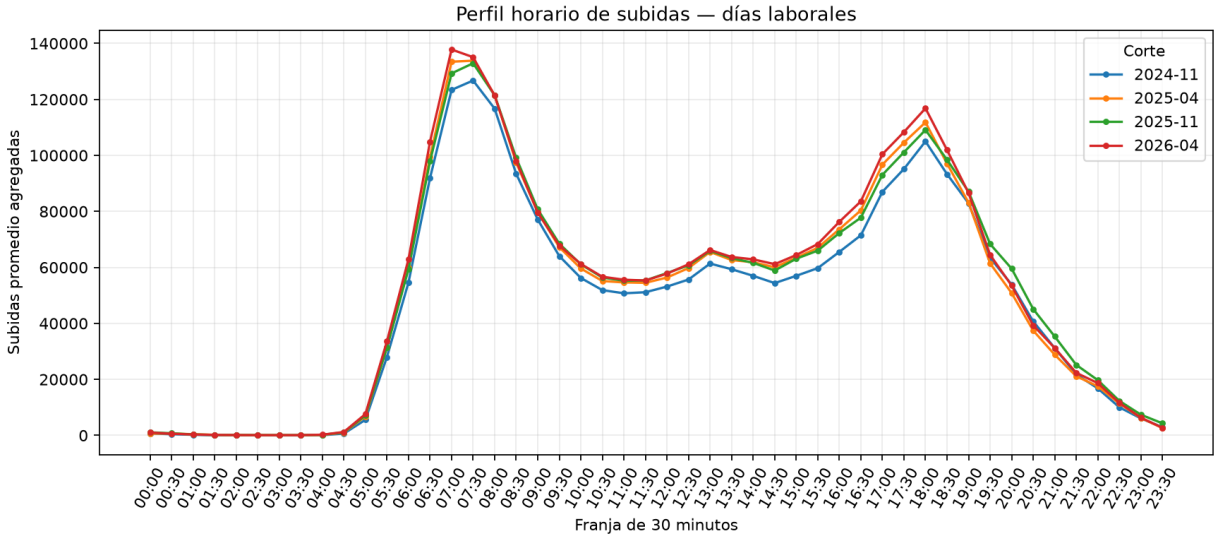


Figura 1. Suma por franja de las subidas promedio laborales. Cada línea es un corte; los puntos siguen horarios, no días consecutivos. Fuente: gráfico existente en el repositorio.

Hallazgo	Evidencia	Qué permite decir
Punta de mañana	Máximo a las 07:30 en los tres primeros cortes y a las 07:00 en abril de 2026.	La hora es relevante para describir la actividad.
Punta de tarde	Segunda concentración alrededor de las 18:00.	El patrón horario tiene más de un máximo.
Diferencia por tipo de día	Laboral/domingo: 2,27; 3,28; 2,87; 3,23, en orden temporal.	El tipo de día es relevante; la razón varía por corte.

Ejemplo de agregación para interpretar un ranking

Comuna	Suma laboral de abril de 2026
Santiago	241.543,80
Maipú	211.066,60
Las Condes	200.337,60

El ranking suma las 48 franjas laborales de cada comuna. No es un conteo mensual ni de personas únicas. Identifica las comunas con mayor medida agregada entre las 36 comparables. Los gráficos muestran asociaciones; no establecen por sí solos las causas de las diferencias ni el efecto de cambiar frecuencias.

Otros gráficos del repositorio: subidas_por_corte_y_dia.png y top_comunas_2026_laboral.png. Todos conservan el alcance de Subidas_Promedio. [D]

ETAPA II / 09

Qué aprende el modelo y por qué usa esas variables

Regresión significa predecir un número. Aquí se compara HistGradientBoosting con dos baselines, métodos simples que permiten medir si la complejidad adicional aporta una mejora. [D]

Antes: historial real de Maipú, laboral, 07:00

Nov. 2024	Abr. 2025	Nov. 2025	Abr. 2026: valor a evaluar
12.100	12.582,4	12.200,6	13.189

Referencia	Cálculo para abril de 2026	Por qué se compara
Último corte	12.200,6	Usa la persistencia: repetir lo más reciente.
Media histórica	(12.100 + 12.582,4 + 12.200,6) / 3 = 12.294,33	Reduce la dependencia de un único corte, aunque puede diluir cambios recientes.

Después: variables que recibe el ML para esa fila

Variable	Valor del ejemplo	Qué aporta / por qué se representa así
comuna / tipo_dia	MAIPÚ / LABORAL	Distinguen contextos con niveles y patrones diferentes.
mes / corte_idx	4 / 3	Mes del corte y posición temporal 0, 1, 2, 3. El índice ordena; no mide meses transcurridos.
hora_sin / hora_cos	0,9659 / -0,2588	Codificación cíclica de 07:00: conserva la cercanía entre fin e inicio del día.
lag_prev_log	log(1 + 12.200,6) = 9,4093	Historial más reciente de esa misma combinación.
history_mean_log	log(1 + 12.294,33) = 9,4170	Promedio histórico de la combinación.

Rezago o lag: valor de un período anterior. Aquí es el corte previo: noviembre de 2025 para predecir abril de 2026. No es la media hora anterior. **relleno_cero** se guarda para auditar; no está entre las variables del ML.

Por qué se codifican y transforman los datos

One-hot: una categoría se convierte en indicadores 0/1. Por ejemplo, “tipo_dia = LABORAL” activa su columna y deja en 0 las de sábado y domingo. Así no se impone un orden numérico entre categorías. Esos ceros codifican categorías; no representan subidas.

log(1 + valor): comprime diferencias de escala y acepta el cero porque log(1) = 0. Se aplica a los antecedentes y al objetivo del entrenamiento; la predicción vuelve a la escala original. Es una elección del primer modelo, no una eliminación de observaciones extremas. [D]

ETAPA II / 10

Cómo se separa el pasado del futuro

Entrenar: aprender relaciones usando ejemplos cuyo objetivo ya se conoce.
Evaluar: comparar el pronóstico con un valor que no se usó como objetivo al ajustar ese modelo.
Fuga de información: usar datos que no estarían disponibles al momento de pronosticar.

Antes y después de construir ejemplos supervisados

Prueba	Historia disponible	Cortes objetivo que usa el ML al entrenar	Filas ML
Abr. 2025	Nov. 2024	Ninguno con antecedentes previos; solo baselines.	0
Nov. 2025	Nov. 2024 y abr. 2025	Abril de 2025, usando noviembre de 2024 como antecedente.	5.184
Abr. 2026	Nov. 2024, abr. 2025 y nov. 2025	Abril y noviembre de 2025, cada uno con sus antecedentes anteriores.	10.368

El panel tiene 20.736 filas, pero el ML no entrena con todas para predecir abril de 2026. Las 5.184 de abril de 2026 se evalúan; las 5.184 iniciales de noviembre de 2024 sirven como antecedentes, pues no tienen un corte previo propio. El entrenamiento final tiene 10.368 filas etiquetadas. [D]

Ejemplo real del cambio de rol del objetivo

Fila que se construye	Valores históricos permitidos	Objetivo para entrenar o evaluar
Maipú / laboral / 07:00 noviembre de 2025	12.100 (nov. 2024) y 12.582,4 (abr. 2025)	12.200,6: se usa para entrenar en la prueba final.
Maipú / laboral / 07:00 abril de 2026	12.100, 12.582,4 y 12.200,6	13.189: se reserva para medir el error final.

Por qué se hace: el objetivo práctico es pronosticar un corte posterior. La separación temporal evalúa esa situación y construye los antecedentes con el pasado de cada fila.

Qué implica: solo hay tres cortes previos al test final. Muchas combinaciones geográficas y horarias no equivalen a muchos escenarios temporales independientes.

Qué modelo se ajustó

HistGradientBoosting construye árboles sucesivos para corregir errores del conjunto. Los árboles permiten relaciones no lineales entre horarios, comunas e historial. Se usó una configuración inicial: 200 iteraciones, learning_rate 0,05, hasta 15 hojas por árbol, regularización L2 = 2, random_state = 42 y early_stopping desactivado. La regularización limita la complejidad; no garantiza generalización. [D]

En la validación de noviembre de 2025, el único corte objetivo de entrenamiento es abril. La categoría mes=11 no se vio al ajustar el codificador y se maneja con handle_unknown="ignore". Es una restricción concreta del experimento; no demuestra por sí sola la causa de su peor resultado.

ETAPA II / 11

Antes y después del pronóstico: cómo se mide el error

Ejemplo real: último corte frente a abril de 2026

Comuna (laboral, 07:00)	Pronóstico: último corte	Observado: abr. 2026	Error absoluto
Maipú	12.200,6	13.189	988,4
Santiago	8.796,4	9.477,4	681
Las Condes	8.895,8	10.060,6	1.164,8

MAE de estas tres filas = (988,4 + 681 + 1.164,8) / 3 = **944,73**. Es una demostración con tres casos; la métrica oficial promedia las 5.184 filas del corte. El error absoluto toma la magnitud de la diferencia, sin que sobreestimar compense subestimar. [C, E]

Resultados globales: prueba final de abril de 2026

Método	MAE	RMSE	WAPE
Último corte	101,13	213,38	11,41 %
Media histórica	89,27	180,97	10,07 %
HistGradientBoosting	70,82	164,90	7,99 %

Métrica	Cómo se calcula / por qué se utiliza
MAE	Promedio de |observado - pronosticado|. Comunica un error típico en unidades de la medida objetivo.
RMSE	Raíz del promedio de (observado - pronosticado)². Penaliza más los errores grandes.
WAPE	100 × suma de errores absolutos / suma observada. Resume el error relativo agregado y admite celdas con valor cero.
MAPE positivos	Promedia errores porcentuales solo donde el observado es mayor que 0. Evita dividir por cero; valores pequeños pueden pesar mucho.

MAE 70,82 significa una desviación media de unas 71 unidades de subidas promedio por celda. WAPE 7,99 % no es una probabilidad de acierto. El MAPE positivo del ML es 21,26 %. Menor valor es mejor en las cuatro métricas.

Resultado que limita la conclusión: en noviembre de 2025, MAE de media histórica = **65,32** y MAE de ML = **147,12**. El ML mejora al final, pero no de manera consistente entre períodos. Sus cifras se toman del CSV guardado; no se reentrenó para este informe.

ETAPA II / 12

Qué decisiones están justificadas y cuáles siguen abiertas

Decisión	Motivo y beneficio	Costo o verificación pendiente
Filtrar BUS	Alinea el conjunto con el problema de buses.	Deja fuera otros modos; sus filas no son errores.
Agrupar por comuna	Ajusta la escala del dato al pronóstico implementado.	Pierde detalle por paradero y no resuelve asignación de frecuencias.
Usar 36 comunas comunes	Compara la misma cobertura y permite antecedentes para cada comuna.	Excluye zonas válidas del corte final; generalización geográfica limitada.
Completar ausencias a 0	Hace regular el panel y alinea claves entre cortes.	Supuesto sin confirmar; puede sesgar aprendizaje y métricas.
Mantener la marca de relleno	Permite localizar qué valores se imputaron.	El modelo actual no usa esa marca ni reporta una prueba separada sin celdas imputadas.
Transformación logarítmica	Comprime la escala y acepta valores cero con log(1+x).	Cambia la escala del ajuste; no hay comparación que demuestre que sea la mejor elección.
Separación temporal	Comprueba predicción hacia un corte posterior.	Pocos cortes y un solo test final restringen la evidencia.

Qué no se hizo en este pipeline

No se descartaron filas por tener cero subidas; se conservaron los ceros observados. Tampoco hay recorte de outliers o winsorización del factor de expansión: el factor no es el target del modelo vigente. El código registra cero descartes por errores de campos en la corrida guardada. [A, B]

Cambios de alcance y comparabilidad

La propuesta de etapa 1 contiene referencias a pasajeros estimados y factores de expansión. El avance implementado usa Subidas_Promedio de la fuente histórica. Además, la ficha de abril de 2026, según la documentación, agrega “u otro medio de pago” a bip!: hay que aclarar si cambió la medición. [G]

Siguiente iteración, por orden de impacto

1. Confirmar el significado de las ausencias y comparar alternativas al cero. **2.** Revisar la comparabilidad de medios de pago. **3.** Ampliar evaluación y contrastar una referencia estacional, por ejemplo el mismo mes del año previo. **4.** Estudiar errores por comuna, horario y presencia de relleno antes de seleccionar un modelo final.

Estado operativo observado: notebook guardado sin salidas incrustadas y guion de presentación disponible. Conviene ejecutar el notebook y preparar las diapositivas antes de exponer. Este informe explica decisiones; no cambia el código ni los datos del análisis.

ETAPA II / 13

Cómo defender el avance y verificar los ejemplos

> “Construimos un panel comparable de 36 comunas y cuatro cortes. Separar ceros observados de ausencias imputadas permite auditar una hipótesis importante. Probamos referencias simples y un primer modelo con evaluación temporal. La mejora final es prometedora, pero todavía no es consistente entre períodos.”

Respuestas que muestran comprensión

Si preguntan...	Respuesta precisa
¿Qué datos eliminaron?	Se filtraron otros modos y, para el modelo, comunas fuera de cobertura común y SIN_COMUNA. Los originales siguen intactos. Agrupar filas no equivale a descartar su suma.
¿Qué cero se inventó?	Cerrillos / laboral / 02:00 / abril de 2025 estaba ausente. Se añadió 0 con relleno_cero=1. Falta validar su significado.
¿Por qué “promedio” tiene decimales?	La fuente ya publica promedios. Sumarlos por comuna puede conservar decimales; no es contar fracciones de una persona individual.
¿Por qué no declarar ganador al ML?	Pierde frente a la media histórica en noviembre de 2025 y gana en abril de 2026. Hay pocos cortes para establecer consistencia.

CRISP-DM: comprensión del problema, comprensión y preparación de los datos, modelamiento y evaluación preliminar. El despliegue operativo queda pendiente. **Rúbrica:** etapa 2 pesa 35 %; solicita problema, metodología, preparación, exploración y primer modelo. Entregables: presentación PPT/PDF y notebook anotado. [F, G]

Fuentes y alcance de esta revisión

[A] Etapa_02/codigo/build_panel.py. Filtros, normalización, agregación y rejilla.

[B] Etapa_02/resultados/panel_quality_report.json. Conteos fuente y cobertura guardados.

[C] Etapa_02/resultados/panel_demanda_bus.csv y panel_demanda_bus_modelo.csv. Filas, ausencias, valores y marcas cotejados.

[D] Etapa_02/codigo/etapa_ii_analysis.py. Variables, transformaciones y evaluación.

[E] Etapa_02/resultados/metricas_modelo_inicial.csv. Resultados guardados de los modelos.

[F] Documentacion/Rubrica_Proyecto_2026-02.pdf. Requisitos de la etapa.

[G] README.md, guion_etapa_ii.md, DICCIONARIO_SALIDAS.md y guías de Documentacion/. Contexto, alcance y advertencias.

[O] Datos/Fuentes/Subidas/Subidas_Paradero_Estacion_2026.04_v3(1).xlsx. Hoja SUBIDAS_2026_04: lectura completa de filas y ejemplos con coordenadas.

Se contrastaron los dos paneles, las 1.087 marcas de relleno, los 197 ceros observados y las exclusiones; se verificó la suma del ejemplo contra el Excel original de abril de 2026. Los conteos históricos de origen provienen del reporte guardado. No se reconstruyeron los cuatro cortes ni se volvió a entrenar ML. En una revisión previa se recalcularon los seis MAE de baselines.