Proyecto Semestral de Data Science · Etapa II

Predicción de subidas de buses Oriente y sur de Santiago

Etapa II. Comparación sectorial y etiquetas horarias

Integrantes: Felipe Farfán, Cristóbal Collado, Bastián Seguin · 28 de octubre de 2026

Comparación de oriente y sur

«Evaluar por sectores (oriente y sur) y etiquetar por tipo de horario (alto, medio, bajo, nulo)»

Antes	Etapa II ajustada
Perfil conjunto de las 36 comunas	Dos sectores definidos explícitamente
Puntas de mañana y tarde en el total	Volumen y distribución horaria por sector
Error promedio del modelo	Error por sector y nivel horario

Pregunta: ¿cuánto se parecen los perfiles y en qué horarios cambia la prioridad de análisis?

Indicación del profesor y alcance analítico de esta actualización.

Comunas incluidas en cada sector

16 comunas de la cobertura común. Agrupación definida para esta comparación.

Oriente · 6 comunas

Las Condes, Vitacura, Lo Barnechea, Providencia, La Reina y Ñuñoa.

Sur · 10 comunas

La Cisterna, El Bosque, San Bernardo, La Pintana, San Ramón, San Miguel, La Granja, San Joaquín, Pedro Aguirre Cerda y Lo Espejo.

Volumen: suma de subidas del sector. Forma: porcentaje de su total diario.
Etiquetas: subidas agregadas divididas por el número fijo de comunas.

Los sectores tienen distinto tamaño. La agrupación es analítica y no una zonificación oficial.

Objetivo y estado del avance

Comparar los perfiles horarios y el desempeño del pronóstico entre oriente y sur, con franjas de 30 minutos.

Objetivo específico	Estado
Delimitar dos sectores comparables en los cuatro cortes	Realizado
Comparar volumen y distribución horaria	Realizado
Asignar alto, medio, bajo y nulo con una regla común	Realizado, con control de ausencias
Medir errores por sector y etiqueta horaria	Realizado sobre el modelo inicial
Probar impacto en frecuencias, espera o capacidad	Pendiente, requiere datos de oferta

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Datos y control de cobertura

Subidas de buses del DTPM. Nov-2024, abr-2025 v2, nov-2025 y abr-2026.

Etapa	Decisión y resultado
Fuente	Sumar Subidas_Promedio por comuna, día y franja.
Panel común original	36 comunas. Modelo inicial con 20.736 celdas.
Comparación sectorial	16 comunas × 3 días × 48 franjas × 4 cortes = 9.216 celdas.
Ausencias en los dos sectores	427 celdas comunales añadidas con cero provisional.
Control en las etiquetas	Si falta una comuna en la franja, marcar sin dato completo.

Las métricas principales de esta comparación excluyen objetivos añadidos como cero.

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Regla común de intensidad horaria

x = suma del sector en 30 minutos / número fijo de comunas del sector

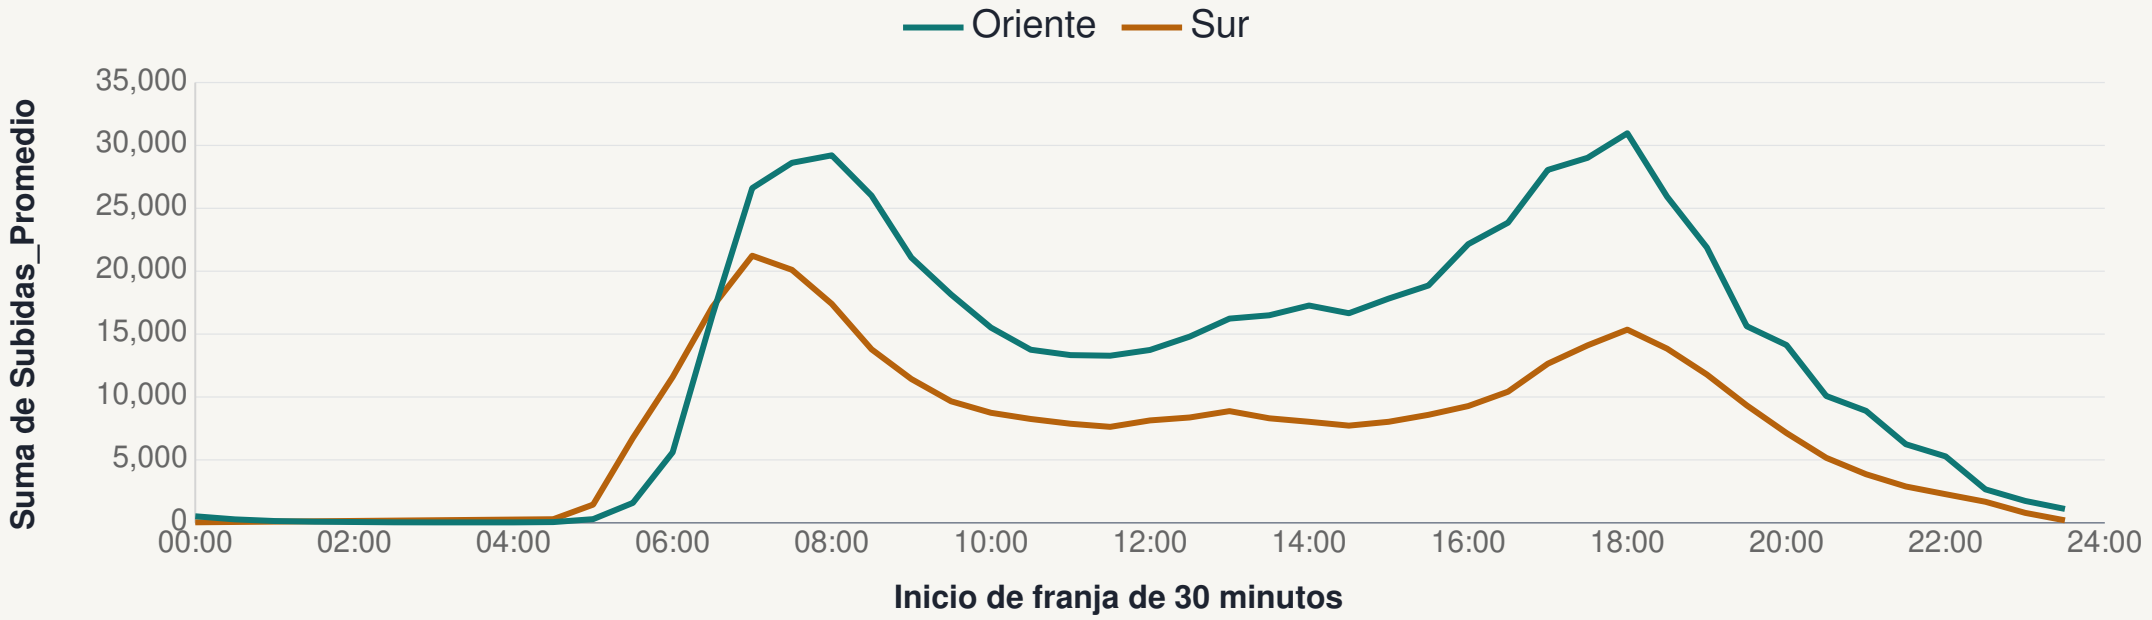
Etiqueta	Regla aplicada a x
Nulo	x = 0, con observación en todas las comunas
Bajo	$0 < x \leq 392{,}16$
Medio	$392{,}16 < x \leq 962{,}52$
Alto	$x > 962{,}52$
Sin dato completo	Falta al menos una comuna. Estado de calidad del dato.

Umbrales: terciles de 768 franjas sectoriales positivas y completas de nov-2024 a nov-2025. Se fijan antes de etiquetar abril de 2026.

Mismos umbrales para ambos sectores y tipos de día. Criterio exploratorio del proyecto.

Sur: máximo a las 07:00. Oriente: 18:00

Día laboral de abril de 2026. Subidas promedio agregadas por franja.

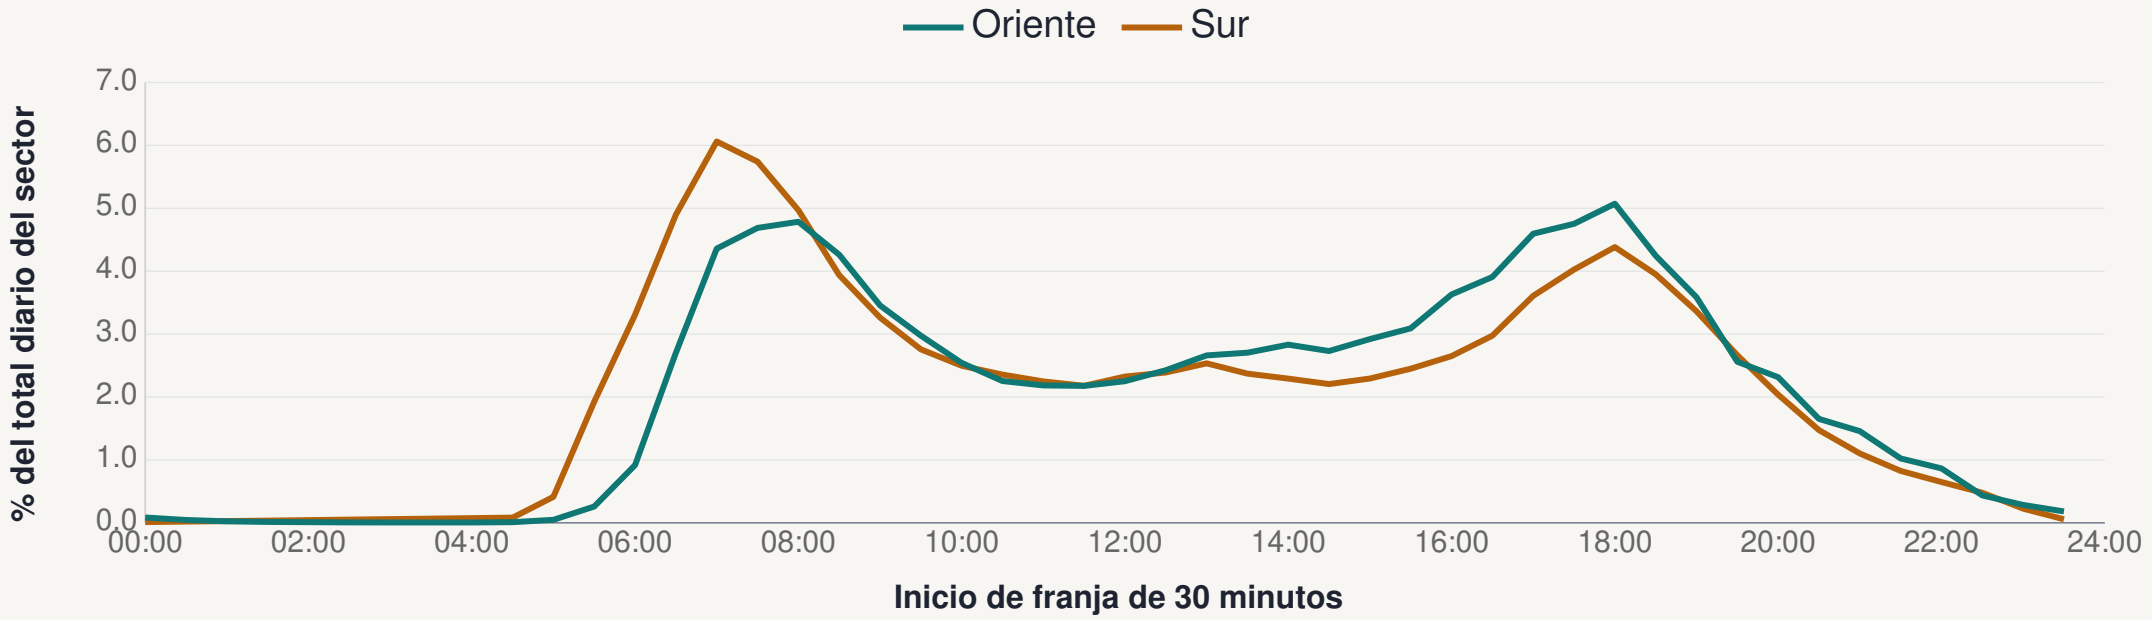


Oriente: 30.964,6 a las 18:00. Sur: 21.232,0 a las 07:00.

Se unen solo observaciones completas. El volumen no está ajustado por población.

Una forma similar, con distinto peso horario

Participación de cada franja en el total laboral del propio sector. Abril de 2026.

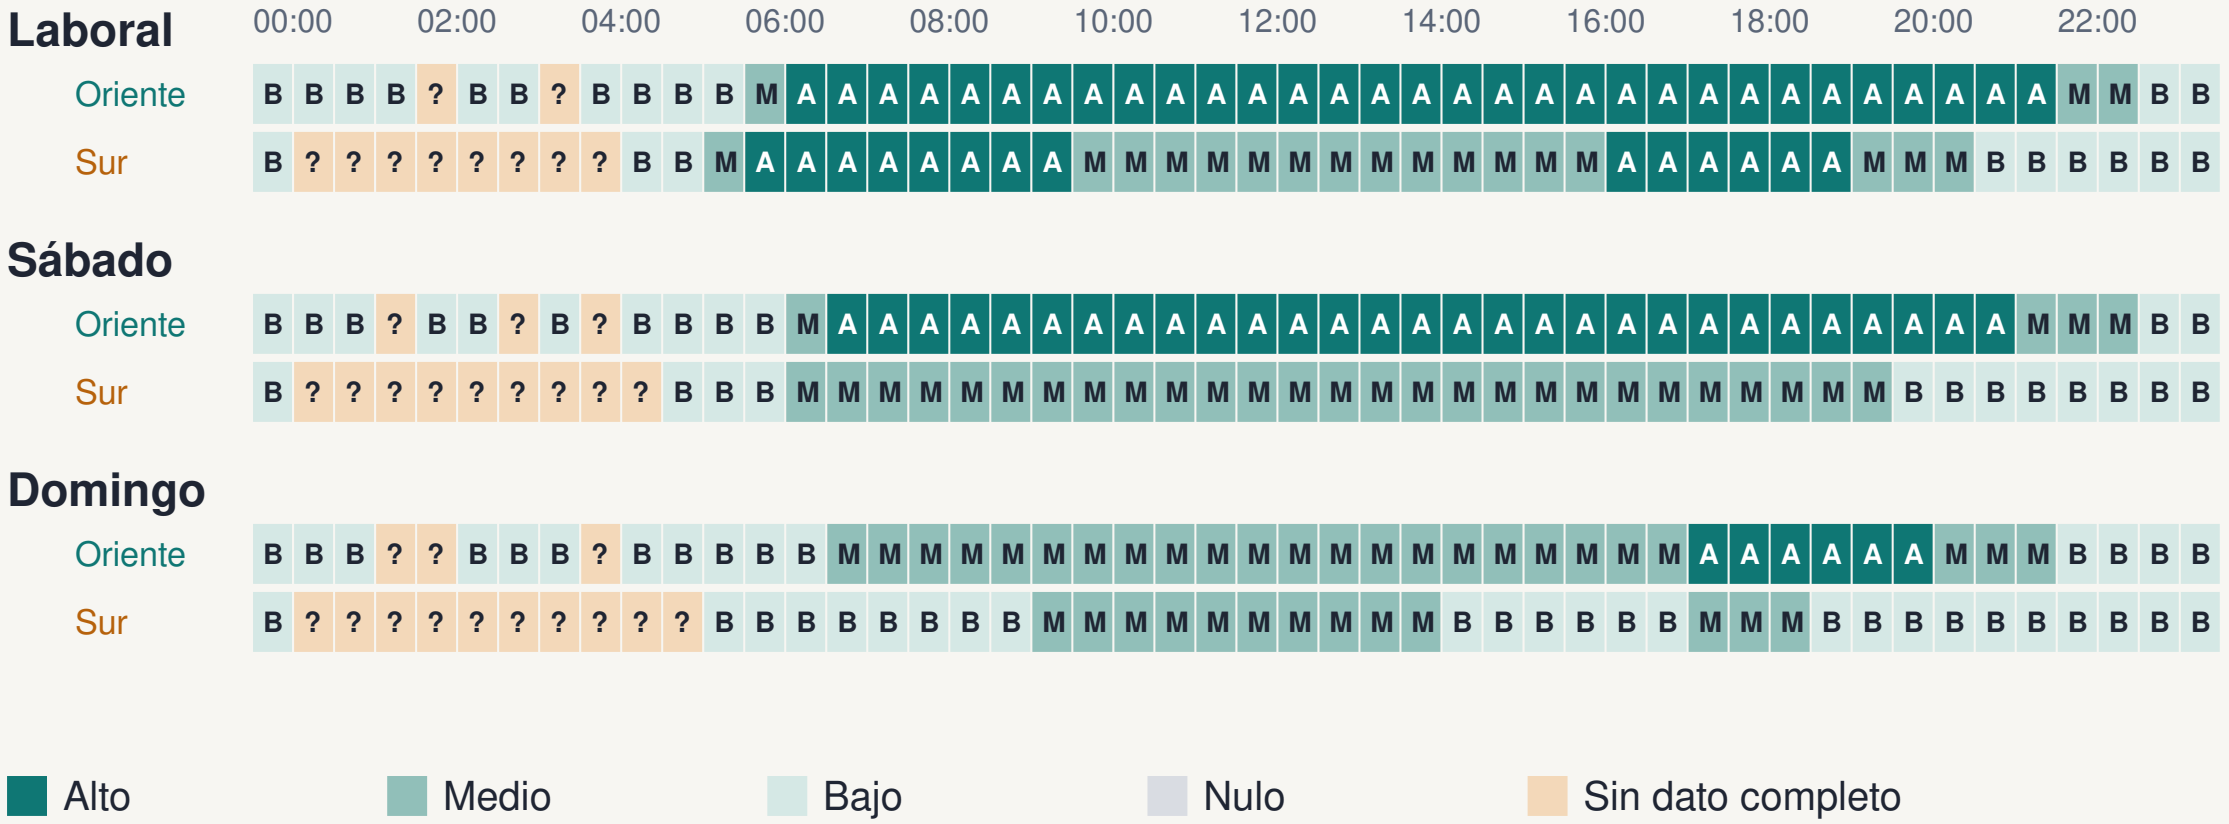


06:00–09:00: sur 28,9 % y oriente 21,7 %.
16:00–20:00: oriente 32,4 % y sur 27,6 %.

Cada sector suma 100 %. El denominador usa las subidas publicadas disponibles.

Etiquetas por sector y tipo de día

Abril de 2026. Cada casilla representa 30 minutos. A: alto, M: medio, B: bajo, N: nulo.



No hay franjas sectoriales nulas confirmadas. «?» indica ausencia de datos, no demanda nula.

Similitudes y diferencias en días laborales

Comparación directa de abril de 2026

Indicador	Oriente	Sur
Franja de máximo	18:00–18:30	07:00–07:30
Parte del día entre 06:00 y 09:00	21,7 %	28,9 %
Parte del día entre 16:00 y 20:00	32,4 %	27,6 %
Franjas altas / 48	31	14
Franjas sin dato completo / 48	2	8

Ambos presentan dos puntas. El sur concentra más actividad relativa en la mañana y oriente en la tarde.

Mismas franjas y regla de etiquetas. Las diferencias no demuestran causas ni déficit de oferta.

El máximo del sur se mantiene en los cuatro cortes

Hora de mayor suma laboral por sector

Corte	Oriente	Sur
Nov. 2024	18:00	07:00
Abr. 2025	18:00	07:00
Nov. 2025	08:00	07:00
Abr. 2026	18:00	07:00

Sur: 07:00 en 4 de 4 cortes.
Oriente: 18:00 en 3 de 4 cortes y 08:00 en noviembre de 2025.

Los máximos identificados tienen cobertura completa. Cuatro cortes no son una serie diaria.

Modelo común, evaluación por sector

Características

Comuna, tipo de día, mes y hora con representación cíclica.

Historial

Último valor y promedio histórico de la misma comuna, día y franja.

Referencias

Último corte y media histórica: métodos simples para medir el aporte del ML.

Se conserva el modelo inicial de 36 comunas. Sus predicciones se evalúan por separado en oriente y sur.

Historial hasta nov-2025 para predecir abr-2026. Sin reentrenamiento por sector.

El modelo mejora en ambos sectores en abril

Error por celda comunal observada. Todos los tipos de día y franjas. Abril de 2026.

Oriente · n = 856

Modelo	MAE	WAPE
Último corte	135,83	10,83 %
Media histórica	107,36	8,56 %
HistGradientBoosting	80,29	6,40 %

Sur · n = 1.335

Modelo	MAE	WAPE
Último corte	55,00	11,24 %
Media histórica	53,50	10,93 %
HistGradientBoosting	38,57	7,88 %

MAE del ML: oriente 80,29 y sur 38,57.
WAPE del ML: oriente 6,40 % y sur 7,88 %.

Sin ajuste nuevo. Evaluación posterior del modelo existente, excluyendo objetivos con cero añadido.

Errores por nivel horario y sector

MAE de HistGradientBoosting en abril de 2026. Objetivos comunales observados.

Horario del sector	Oriente: MAE (n)	Sur: MAE (n)
Bajo	15,30 (234)	27,50 (460)
Medio	99,63 (186)	48,21 (570)
Alto	117,05 (396)	79,59 (140)
Sin dato completo	6,58 (40)	1,33 (165)

Mayor error absoluto en horarios altos en ambos sectores.
Oriente medio: WAPE 12,89 %. Oriente alto: 5,12 %.

Nulo: sin casos sectoriales confirmados para evaluar. n cuenta celdas comunales, no franjas.

La mejora depende del corte de prueba

MAE por sector. Misma evaluación sobre objetivos comunales observados.

Corte	Sector	Media histórica	HistGradientBoosting
Nov. 2025	Oriente	87,15	191,04
Nov. 2025	Sur	38,57	87,13
Abr. 2026	Oriente	107,36	80,29
Abr. 2026	Sur	53,50	38,57

En noviembre de 2025 gana la media histórica en ambos sectores.
En abril de 2026 gana el ML. Falta demostrar una mejora estable.

El contraste sectorial es exploratorio. Abril de 2026 ya se había revisado en el avance original.

Límites de la comparación

Límite	Efecto sobre la interpretación
Cuatro cortes	La regularidad observada requiere más fechas de validación.
Agrupación de 6 y 10 comunas	Sumas y promedios no ajustan población, paraderos ni oferta.
Ausencias y cambio de medición	427 ceros añadidos en estos sectores. Revisar medios de pago.
Umbrales exploratorios	Los terciles no indican saturación. Probar sensibilidad.
Solo subidas registradas	No se corrige evasión ni se miden ocupación, esperas o bajadas.

No se infieren causas residenciales/laborales ni cambios de frecuencia a partir de las curvas.

Próximos pasos hacia la Etapa III

1. Validar ausencias y comparar el tratamiento de ceros.
2. Contrastar terciles con otros umbrales y revisar la delimitación.
3. Ampliar cortes y comprobar el desempeño por sector y horario.
4. Cruzar con oferta y capacidad antes de recomendar frecuencias.

Resultado esperado: una comparación que apoye prioridades de revisión de la oferta.

Conclusiones de la comparación

Hallazgo	Conclusión respaldada
Similitud	Ambos perfiles laborales tienen puntas de mañana y tarde.
Diferencia	Sur concentra más proporción en 06:00–09:00. Oriente en 16:00–20:00.
Horario y pronóstico	El MAE más alto aparece en franjas altas. El error relativo varía por sector.
Consistencia	Sur mantiene su máximo a las 07:00. El ML cambia de posición entre cortes.

Priorizar la revisión de oferta en la mañana del sur y la tarde de oriente, y contrastarla con capacidad y ocupación.

Las curvas orientan dónde estudiar mejoras. El efecto operativo todavía no se ha medido.

Ejemplo real: de paraderos a comuna

Abril de 2026. Cerrillos, día laboral, franja 00:30–01:00.

Antes: cinco filas del Excel

Código de paradero	Subidas promedio
PI24	0,4
PI33	0,2
PI1155	0,2
PI119	0,2
PI58	0,4

Después: una fila comunal

Comuna	Hora	Subidas
Cerrillos	00:30	1,4

0,4 + 0,2 + 0,2 + 0,2 + 0,4 = 1,4

Sumamos el aporte de los paraderos. El panel conserva la suma y reduce el detalle geográfico.

Subidas_Promedio ya es una medida promedio. Puede tener decimales.

Cero observado y cero añadido

La misma combinación: Cerrillos, laboral, 02:00–02:30.

Corte	Antes: panel observado	Después: valor	relleno_cero
Nov. 2024	Fila presente con valor 0	0	0
Abr. 2025	No existe esa fila	0	1
Nov. 2025	Fila presente con valor 0,4	0,4	0
Abr. 2026	Fila presente con valor 0,4	0,4	0

Marca 0: combinación observada. Marca 1: combinación añadida.

Completar ausencias con cero es un supuesto pendiente de confirmar con el DTPM.

Panel común: 197 ceros observados + 1.087 añadidos = 1.284 celdas con valor cero.