Proyecto Semestral de Data Science · Etapa II

Predicción de subidas de buses Oriente y sur de Santiago

Etapa II. Pronóstico sectorial sencillo y etiquetas horarias

Integrantes: Felipe Farfán, Cristóbal Collado, Bastián Seguin · 28 de octubre de 2026

Foco de la Etapa II ajustada

Comparar oriente y sur y anticipar el nivel horario de las subidas registradas.

Decisión	Alcance de esta entrega
Fuente principal	Solo Subidas por Paradero y Estación
Unidad del pronóstico	Sector, tipo de día y franja de 30 minutos
Método principal	Media histórica de la misma combinación
Resultado interpretable	Valor pronosticado y etiqueta de intensidad

¿Podemos anticipar los niveles horarios y reconocer diferencias entre ambos sectores con un método sencillo?

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Comunas incluidas en cada sector

16 comunas de la cobertura común. Agrupación definida para esta comparación.

Oriente · 6 comunas

Las Condes, Vitacura, Lo Barnechea, Providencia, La Reina y Ñuñoa.

Sur · 10 comunas

La Cisterna, El Bosque, San Bernardo, La Pintana, San Ramón, San Miguel, La Granja, San Joaquín, Pedro Aguirre Cerda y Lo Espejo.

Volumen: suma de subidas del sector. Forma: porcentaje de su total diario.
Etiquetas: subidas agregadas divididas por el número fijo de comunas.

Los sectores tienen distinto tamaño. La agrupación es analítica y no una zonificación oficial.

Objetivo y estado del avance

Pronosticar y comparar las subidas de oriente y sur por tipo de día y franja de 30 minutos.

Objetivo específico	Estado
Definir los sectores y revisar su cobertura	Realizado
Comparar perfiles y etiquetar la intensidad horaria	Realizado
Pronosticar con media histórica y último observado	Realizado
Evaluar cantidades, etiquetas y horarios altos	Realizado, evidencia preliminar
Integrar otras fuentes y contrastar con oferta	Fase posterior

Datos principales y control de cobertura

Subidas DTPM: nov-2024, abr-2025 v2, nov-2025 y abr-2026

Paso	Tratamiento aplicado
Filtrar y agrupar	BUS. Sumar por sector, día y franja.
Cobertura seleccionada	16 comunas, dos sectores y cuatro cortes.
Panel sectorial	2 sectores × 3 días × 48 franjas × 4 cortes = 1.152 filas.
Ausencias comunales	427 celdas originales marcadas como añadidas.
Historial y evaluación	Excluir la franja sectorial si falta alguna de sus comunas.

Abr-2026: se evalúan 135 de 144 franjas en oriente y 117 de 144 en el sur.

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Regla común de intensidad horaria

x = suma del sector en 30 minutos / número fijo de comunas del sector

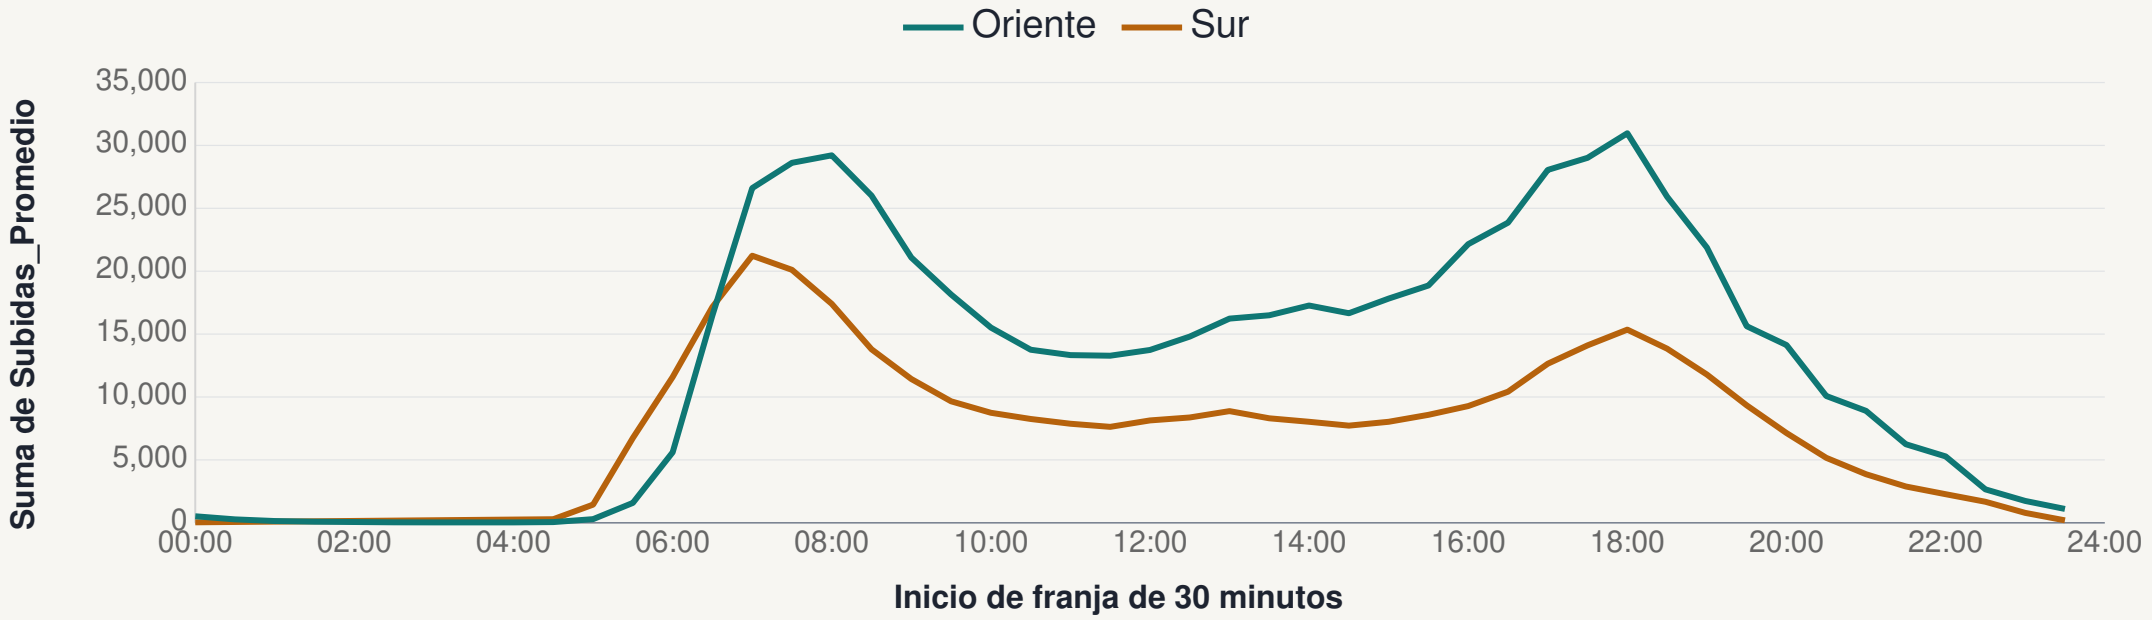
Etiqueta	Regla aplicada a x
Nulo	x = 0, con observación en todas las comunas
Bajo	$0 < x \leq 392{,}16$
Medio	$392{,}16 < x \leq 962{,}52$
Alto	$x > 962{,}52$
Sin dato completo	Falta al menos una comuna. Estado de calidad del dato.

Umbrales: terciles de 768 franjas sectoriales positivas y completas de nov-2024 a nov-2025. Se fijan antes de etiquetar abril de 2026.

Mismos umbrales para ambos sectores y tipos de día. Criterio exploratorio del proyecto.

Sur: máximo a las 07:00. Oriente: 18:00

Día laboral de abril de 2026. Subidas promedio agregadas por franja.

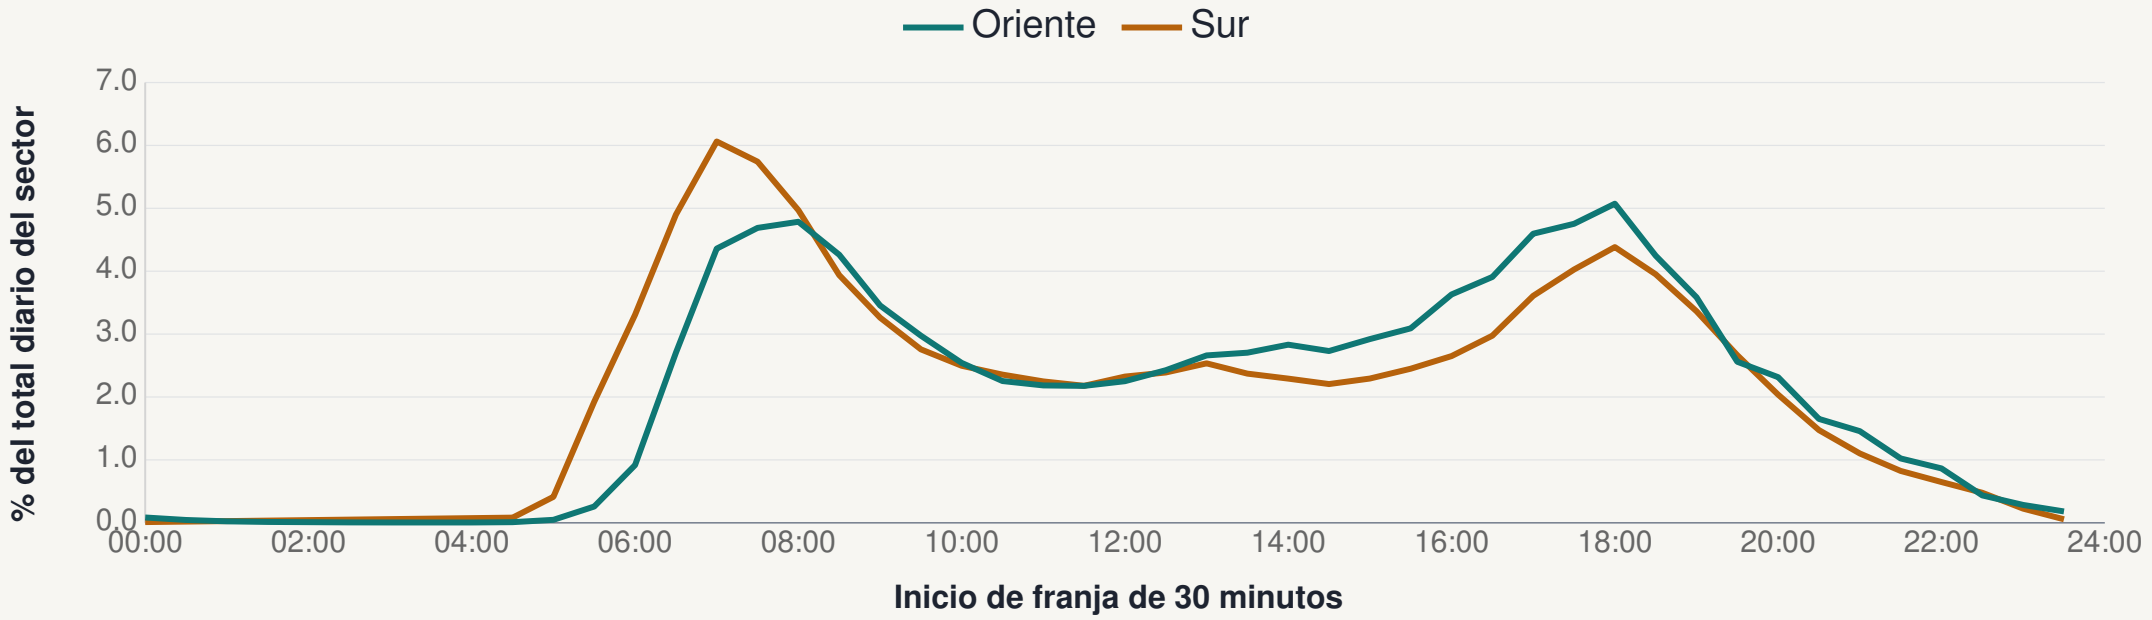


Oriente: 30.964,6 a las 18:00. Sur: 21.232,0 a las 07:00.

Se unen solo observaciones completas. El volumen no está ajustado por población.

Una forma similar, con distinto peso horario

Participación de cada franja en el total laboral del propio sector. Abril de 2026.

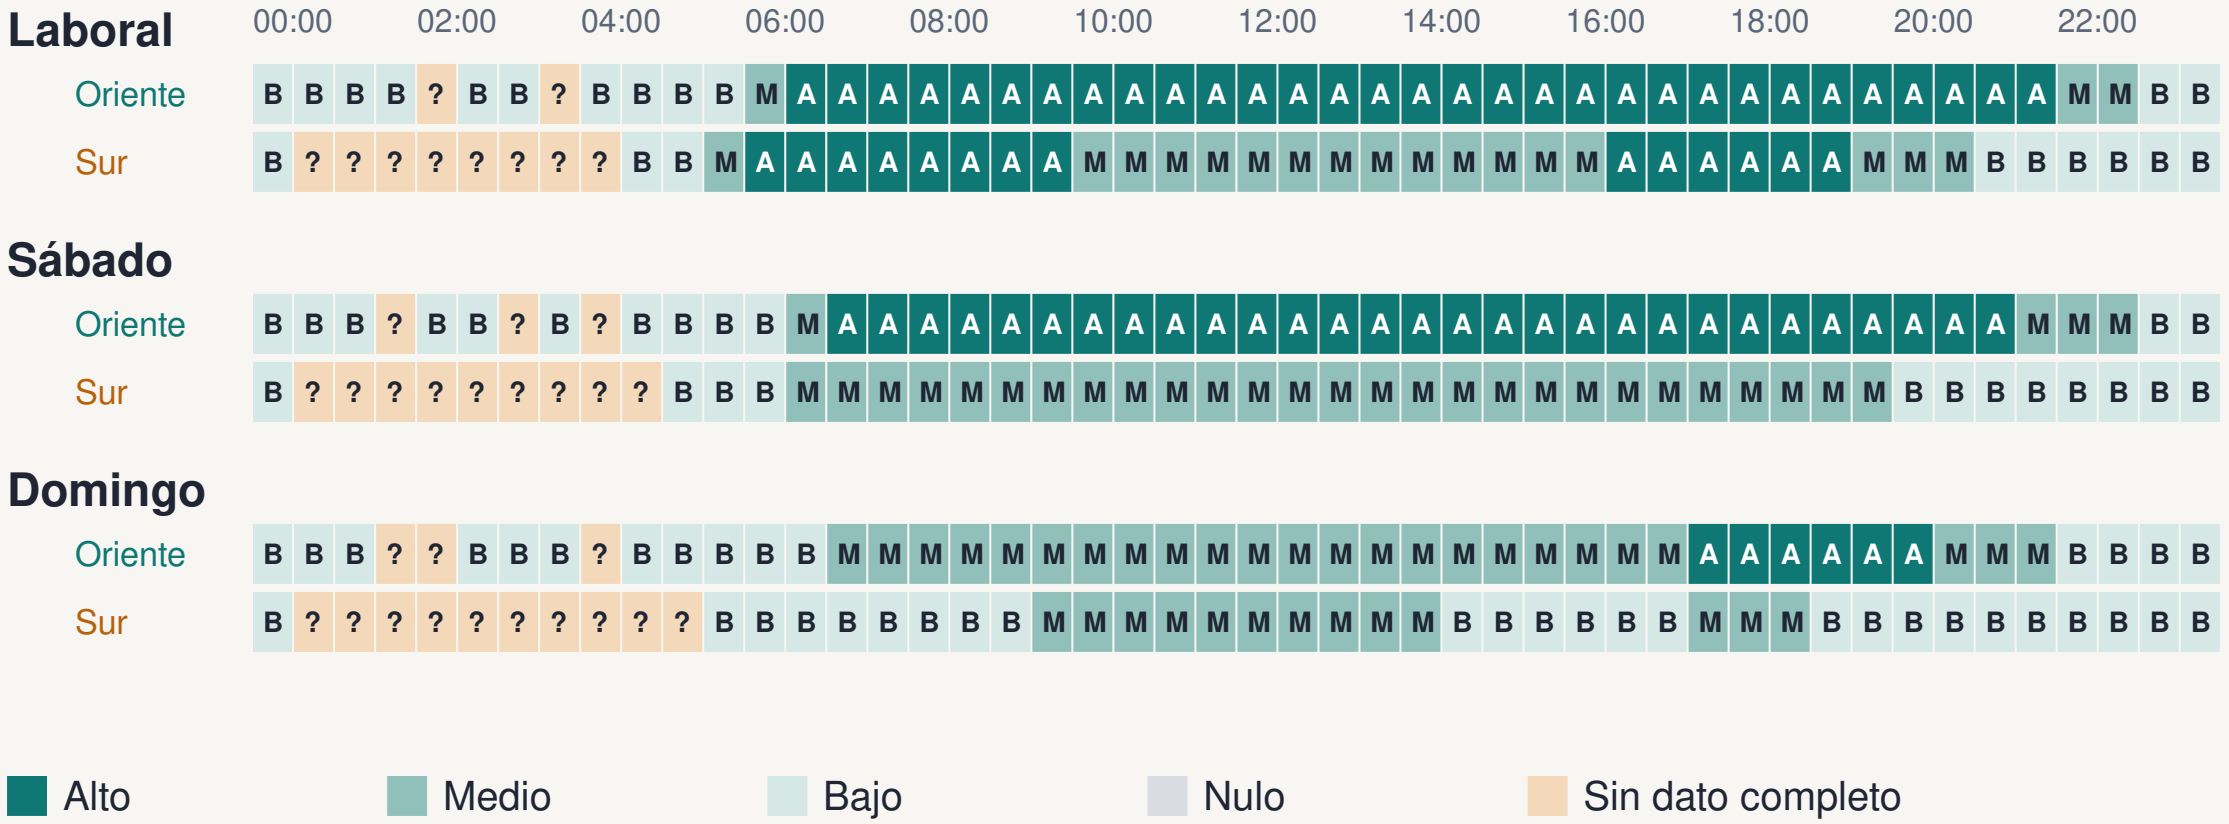


06:00–09:00: sur 28,9 % y oriente 21,7 %.
16:00–20:00: oriente 32,4 % y sur 27,6 %.

Cada sector suma 100 %. El denominador usa las subidas publicadas disponibles.

Etiquetas por sector y tipo de día

Abril de 2026. Cada casilla representa 30 minutos. A: alto, M: medio, B: bajo, N: nulo.



No hay franjas sectoriales nulas confirmadas. «?» indica ausencia de datos, no demanda nula.

Similitudes y diferencias en días laborales

Comparación directa de abril de 2026

Indicador	Oriente	Sur
Franja de máximo	18:00–18:30	07:00–07:30
Parte del día entre 06:00 y 09:00	21,7 %	28,9 %
Parte del día entre 16:00 y 20:00	32,4 %	27,6 %
Franjas altas / 48	31	14
Franjas sin dato completo / 48	2	8

Ambos presentan dos puntas. El sur concentra más actividad relativa en la mañana y oriente en la tarde.

Mismas franjas y regla de etiquetas. Las diferencias no demuestran causas ni déficit de oferta.

El máximo del sur se mantiene en los cuatro cortes

Hora de mayor suma laboral por sector

Corte	Oriente	Sur
Nov. 2024	18:00	07:00
Abr. 2025	18:00	07:00
Nov. 2025	08:00	07:00
Abr. 2026	18:00	07:00

Sur: 07:00 en 4 de 4 cortes.
Oriente: 18:00 en 3 de 4 cortes y 08:00 en noviembre de 2025.

Los máximos identificados tienen cobertura completa. Cuatro cortes no son una serie diaria.

Qué cambió en el enfoque del modelo

Se conserva Subidas y se acota la unidad de predicción a dos sectores

Aspecto	Avance comunal anterior	Entrega sectorial actual
Unidad	Comuna, tipo de día y franja	Sector, tipo de día y franja
Cobertura	36 comunas comunes	Oriente: 6 comunas. Sur: 10.
Método principal	HistGradientBoosting y referencias	Media histórica y último observado
Entradas	Comuna, calendario e historial	Historial de la misma zona y horario
Salida	Cantidad de subidas comunales	Cantidad sectorial y nivel horario

HistGradientBoosting se conserva como antecedente del avance.

Las métricas comunales anteriores y las sectoriales actuales tienen unidades distintas.

Cómo funcionaba HistGradientBoosting

Modelo de árboles del avance comunal anterior

1. Estimación inicial

Parte de una primera estimación de las subidas.

2. Correcciones

Añade árboles sucesivos para reducir el error del conjunto.

3. Predicción

Combina los ajustes y obtiene una cantidad pronosticada.

Entradas anteriores: comuna, tipo de día, calendario, hora e historial.

«Hist» agrupa valores numéricos en intervalos durante el entrenamiento.

Su desempeño por sector requeriría una nueva comparación.

Referencia conceptual: documentación oficial de scikit-learn. Aplicación: avance comunal.

Cómo funciona el modelo sectorial actual

Media histórica para cada sector, tipo de día y franja de 30 minutos

Paso	Proceso	Resultado
Preparación	Sumar Subidas de la misma zona, día y franja. Conservar solo antecedentes completos.	Historial comparable
Pronóstico	Promediar los valores de los cortes anteriores para esa combinación.	Cantidad del sector
Etiqueta	Dividir por el número fijo de comunas y aplicar los umbrales históricos.	Nulo, bajo, medio o alto
Evaluación	Comparar el pronóstico con un corte posterior y con el último observado.	MAE, WAPE y coincidencia de etiquetas

Cantidad y etiqueta son dos resultados del mismo procedimiento.

El método actual calcula promedios históricos. No entrena árboles ni un clasificador adicional.

Ejemplo: sur, laboral, 07:00–07:30

Las mismas comunas y franja en los tres cortes anteriores a abril de 2026

Corte o resultado	Suma de Subidas_Promedio
2024-11	18.728,0
2025-04	20.766,0
2025-11	19.844,0
Media histórica para abr-2026	19.779,33
Observado abr-2026	21.232,00

Pronóstico: 1.977,93 por comuna, nivel alto.
Observado: 2.123,20 por comuna, nivel alto.

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Resultados del pronóstico sectorial

Abril de 2026. Días laborales, sábados y domingos. Solo franjas evaluables.

Sector	Método	MAE	WAPE	n / 144
Oriente	Media histórica	618,23	7,78 %	135
Oriente	Último observado	781,48	9,84 %	135
Sur	Media histórica	509,51	9,13 %	117
Sur	Último observado	509,30	9,12 %	117

La media histórica mejora en oriente. En el sur, ambos métodos dan resultados prácticamente iguales.

MAE: subidas promedio agregadas por sector, día y franja. WAPE: error absoluto relativo al volumen.

Evaluación de las etiquetas pronosticadas

Media histórica. Abril de 2026. Filas: observado. Columnas: pronosticado.

Oriente: 83,7 % de coincidencia

Real / pron.	Nulo	Bajo	Medio	Alto
Nulo	0	0	0	0
Bajo	0	38	0	0
Medio	0	1	14	16
Alto	0	0	5	61

Sur: 88,0 % de coincidencia

Real / pron.	Nulo	Bajo	Medio	Alto
Nulo	0	0	0	0
Bajo	0	37	9	0
Medio	0	3	54	0
Alto	0	0	2	12

Oriente: 16 de 31 franjas medias se pronostican altas.
Sur: se detectan 12 de las 14 franjas altas.

Nulo: sin casos observados confirmados. La coincidencia de etiquetas no equivale a precisión del volumen.

Comparación temporal de los métodos

WAPE por sector. Cada prueba utiliza únicamente sus cortes anteriores.

Prueba	Sector	Media histórica	Último observado
Nov. 2025	Oriente	5,77 %	9,28 %
Nov. 2025	Sur	5,31 %	7,93 %
Abr. 2026	Oriente	7,78 %	9,84 %
Abr. 2026	Sur	9,13 %	9,12 %

En noviembre de 2025 la media mejora en ambos sectores.
En abril de 2026, su ventaja se mantiene solo en oriente.

Solo cuatro cortes. La selección del enfoque es posterior a haber revisado abril de 2026.

Limitaciones y siguiente fase

Límite actual	Qué queda por resolver
Cuatro publicaciones	Ampliar la evaluación temporal antes de generalizar.
Cobertura incompleta	Confirmar ausencias. Informar franjas excluidas y sin historial.
Umbrales exploratorios	Comprobar sensibilidad de alto, medio y bajo.
Comparación territorial	Revisar población y oferta antes de recomendar frecuencias.
Fuentes complementarias	Etapas, Viajes y geografía se integrarán en una fase posterior.

Esta entrega utiliza exclusivamente la fuente principal de Subidas.

Fuente: DTPM, Subidas por Paradero y Estación. Cálculos del proyecto.

Conclusiones de la Etapa II

Resultado	Conclusión respaldada
Patrón horario	Ambos sectores tienen dos puntas. El sur concentra más proporción en la mañana y oriente en la tarde.
Pronóstico sencillo	La media histórica es una referencia útil en oriente. En el sur no supera al último observado en abril.
Etiquetas	Coincidencia de 83,7 % en oriente y 88,0 % en sur, con dificultades en niveles medios de oriente.
Aplicación	Orientar una revisión de oferta en horarios específicos, pendiente de datos de capacidad y ocupación.

Se obtuvo una comparación reproducible de sectores, cantidades y niveles horarios.

Próxima fase: ampliar la validación y luego incorporar las fuentes complementarias.